离线资料库软件

软件说明书

版本号：V1.0

二〇二六年十月

一、软件概述

离线资料库软件是一款运行于 HarmonyOS 终端的个人资料管理与全文检索工具。用户可以把笔记、讲义、摘录等文字内容存入本机资料库，之后用关键词快速找回，并直接看到命中位置在原文中的高亮。

软件的核心设计目标是「完全离线」：不申请任何网络权限，不发起任何网络请求，全部索引与检索都在设备本地完成。这一约束不是事后补充，而是从第一行代码起就作为前提。

1.1 目标用户

- 需要在手机上随时查阅自己积累的资料的学生与研究者
- 对隐私敏感、不愿把笔记上传到云端的用户
- 网络条件受限（地铁、飞机、会场）时需要检索资料的用户

1.2 主要解决的问题

手机上的资料分散在备忘录、聊天记录、截图、PDF 中，找起来靠记忆和翻找。系统自带的搜索往往只匹配标题或文件名，不进入正文。本软件把正文切成片段并建立倒排索引，使得「我记得好像在哪写过这个词」能够被检索到。

二、运行环境

2.1 硬件环境

- 设备形态：手机、平板、个人计算机（2in1）
- 内存：建议 4 GB 及以上
- 存储：软件本体约 1 MB，资料占用取决于用户导入的内容量

2.2 软件环境

- 操作系统：HarmonyOS NEXT
- 编译 SDK：HarmonyOS SDK API 12 及以上
- 已验证运行环境：MateBook Pro（HAD-W32，2in1 形态，API 23）

2.3 权限说明

本软件不申请任何系统权限，包括网络权限。安装后可通过系统的应用信息页面确认其权限列表为空。这是「数据不出设备」这一主张在权限层面的直接体现。

三、主要功能

3.1 资料导入

在「资料」页输入标题与正文，点击「加入资料库」即完成入库。导入时软件会自动把长文本切分成便于检索的片段，并为每个片段建立索引。

3.2 全文检索

在「搜索」页输入关键词，软件按 BM25 算法对全部片段打分并排序返回结果。命中的关键词在结果中以红色加粗高亮显示，便于快速判断相关性。

3.3 检索深度自适应

软件默认采用「按得分分布自适应」的检索深度策略：根据候选结果的得分是否出现明显断层，自动决定返回几条结果，而不是固定返回若干条。用户也可以切换到「固定 3 条」模式作对照。

这是本软件区别于一般检索工具的关键设计：返回条数由内容本身的区分度决定，而不是由一个人为设定的常数决定。

3.4 决策解释

每次检索后，界面会显示本次决策的依据，包括：实际返回条数、深度来源（自适应还是固定）、受限因素（时间/内存/电量）、候选数量。用户因此可以理解「为什么给我这几条」，而不是面对一个黑箱。

3.5 资料管理与增量删除

「资料」页列出全部已入库文档，显示来源与字数，并支持逐条删除。删除采用增量方式：只标记失效片段并在比例超限时自动整理，不需要重建整个索引。

3.6 拍照导入与文字识别

软件集成了系统的 CoreVisionKit 文字识别能力，可以将图片中的文字转换为可检索的文本。识别结果会附带一个质量分档，用于决定「直接收下 / 提示重拍 / 丢弃」。

需要说明的是：文字识别引擎本身不返回标量置信度，仅有文本块信息，因此质量分档由本软件根据块数与文本长度估计，属于经验性判断。

3.7 设备能力探测

「高级」页提供设备能力探测功能，用系统的能力查询接口列出文字识别、端侧检索、视觉基础、智能体框架等能力在当前设备上是否可用。这一功能的价值在于：软件可以据此决定启用哪些特性，而不是在调用失败时崩溃。

3.8 设备内自测

「高级」页提供设备内自测功能，在设备上直接运行 14 项检查并逐条显示结果，覆盖切词、分块、打分、排序、高亮、存储往返、文字识别判定与流水线全流程。自测全部通过时会显示「全部通过：14 / 14」。

四、技术特点

4.1 中文切词不依赖词典

中文检索的常见做法是引入分词词典，但词典会带来体积、维护与未登录词三类问题。本软件采用「单字 + 二元组」的切词方式：既产生单字索引保证召回，又产生相邻两字的组合保证区分度，完全不需要词典。

4.2 BM25 排序

打分采用 BM25 算法，参数取 k1 = 1.5、b = 0.75。该算法同时考虑词频饱和与文档长度归一化，避免长文档因为「字多」而获得不当优势。

4.3 墓碑式增量删除

删除文档时不为每个片段重排索引，而是把片段标记为失效（墓碑）。当墓碑占比超过 20% 时自动整理一次。相比每次删除都全量重建，这一策略把删除开销从「与库规模成正比」降为「与删除量成正比」。

4.4 索引与持久化分离

持久化只保存原始文档，索引在启动时重建。这样索引格式变化不会导致旧存档失效，而重建在常见规模下是秒级操作。

4.5 文字识别做成接口而非直接依赖

文字识别能力被定义为接口，真实实现由上层注入。这样在没有该能力的设备上软件仍可正常启动并使用其余功能，而不是因为依赖缺失而无法运行。

五、操作流程

5.1 首次使用

启动软件后默认进入「搜索」页。首次启动会自动放入一份示例资料，用户可以直接搜索示例内容以了解软件行为。

5.2 导入自己的资料

① 切换到底部「资料」页；② 在标题框填写标题（可留空）；③ 在正文框粘贴或输入内容；④ 点击「加入资料库」。导入成功后页面顶部的统计数字会更新。

5.3 检索

① 切回「搜索」页；② 输入关键词；③ 点击「搜索」或按回车。结果按相关度排序，关键词高亮显示。页面顶部会显示本次决策的依据。

5.4 切换检索深度

在「搜索」页打开或关闭「检索深度」开关即可在自适应与固定 3 条之间切换。切换后需要重新搜索才会生效。

5.5 运行自测

切换到「高级」页，点击「运行设备内自测」，稍候即可看到 14
项检查的逐条结果。每一项前面显示对勾表示通过，叉号表示未通过并给出原因。

六、数据结构与模块说明

6.1 主要数据结构

- 文档（DocItem）：标识、标题、来源类型、原始位置、加入时间、正文
- 片段（Chunk）：所属文档、序号、正文起止位置、片段文本
- 命中（Hit）：命中的片段、相关度得分、命中词及其出现次数、高亮区间
- 搜索选项（SearchOptions）：固定条数、最少条数、最多条数
- 资源预算（BudgetInput）：时间预算、内存预算、电量百分比

6.2 模块划分

- 切词模块：把文本转换为检索词序列
- 索引模块：倒排表维护、BM25 打分、片段切分、命中定位
- 检索模块：诊断、自适应条数决策、资源预算决策、结果组装
- 存储模块：文档集合的增删改查与序列化
- 识别模块：识别引擎接口、质量分档策略、真实引擎实现
- 流水线模块：把上述模块组合成对界面友好的服务接口

七、已验证情况

为避免夸大，此处只陈述实际做过的验证：

- 核心算法：87 项单元测试在开发机上全部通过
- 真实语料：以 64 份文档（约 44 万字）为语料，150 条已知答案查询的召回率为 100%
- 编译兼容：通过 HarmonyOS ArkTS 编译器编译，无错误
- 真机运行：在 MateBook Pro（2in1 形态，API 23）上安装、启动、运行正常
- 设备内自测：14 项检查在该真机上全部通过
- 真实文字识别：内置测试图识别成功，输出 181 字，耗时 222 毫秒

尚未验证的部分：相机拍照路径、手写体与低质量图片的识别效果、手机形态设备上的表现。这些限制在技术文档中有明确记录。