离线资料库软件 V1.0 软件说明书

软著登记材料

软著登记材料

软件名称：离线资料库软件　版本号：V1.0

开发方式：合作开发　权利取得：原始取得

一、软件概述

1.1 软件定位

离线资料库软件是一款运行于 HarmonyOS 设备的个人资料检索工具。用户把课堂讲义、书页照片、笔记片段导入后，可以用自然语言描述记得的内容，软件在本机完成检索并返回原文片段与高亮位置。

核心特征：全程离线，不发起任何网络请求，资料不出设备。

1.2 解决的问题

纸质与碎片资料"存得下、找不回"：

场景	现状
课堂板书、讲义、PPT 拍成照片	躺在相册里，只能靠翻，无法按内容搜索
书上的重点、资料截图	存进备忘录后检索不到原文
图书馆、地铁、教室等弱网/无网环境	云端笔记类应用直接不可用
学习资料、证件、内部讲义	上传云端有隐私顾虑

本软件针对的正是这四类场景：要找得到、不用联网、不用上传。

1.3 与同类方案的差异

维度	系统备忘录/图库	云端笔记	扫描类应用	本软件
全程离线	是	否	部分	是
数据不出设备	是	否	部分	是
可按内容检索原文	部分	是	否	是

跨来源统一建库	否	是	否	是
可追溯出处与高亮	否	部分	否	是

二、运行环境

项	要求
操作系统	HarmonyOS NEXT（API 12 及以上）
设备形态	手机、平板
运行内存	2 GB 及以上
存储空间	50 MB 及以上（随资料量增长）
网络	不需要（软件不申请网络权限）
开发语言	ArkTS / TypeScript
开发工具	DevEco Studio 26.0

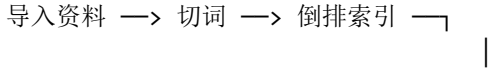
三、软件架构

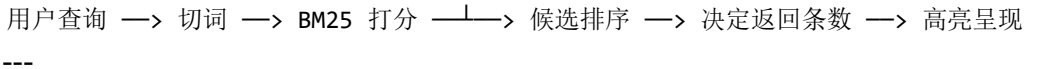
3.1 模块划分

软件由七个核心模块与一个界面层构成：

模块	职责
types	数据结构定义（文档、片段、命中、预算）
tokenize	中英文切词
index	倒排索引构建、BM25 打分、文本分块、高亮定位
search	检索入口、自适应结果数量决策、资源预算决策
store	文档存储与 JSON 持久化
ocr	光学字符识别抽象层与识别质量判定
pipeline	流水线编排（导入 → 分块 → 建索引 → 检索）
pages/Index	用户界面

3.2 数据流





四、功能说明

4.1 资料导入

软件支持三种导入方式：

方式	说明
粘贴文本	用户直接粘贴或输入内容，无需 OCR
拍照识别	调用设备 OCR 能力识别图片文字（需设备支持）
文件导入	从本地文件选择导入（后续版本）

导入流程：

- 用户填写标题（可留空，默认"未命名资料"）
- 输入或识别文本内容
- 软件按内容长度自适应选择分块大小
- 文本被切成可检索片段并加入索引
- 界面显示入库结果与片段数量

4.2 资料检索

操作：在搜索框输入关键词或描述，点"搜索"。

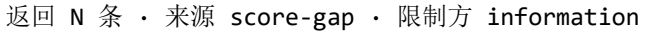
检索流程：

- 对查询串做切词
- 在倒排索引中定位候选片段
- 用 BM25 算法对候选打分并排序
- 根据得分分布决定返回几条（详见 5.2）
- 在结果中高亮显示命中词

结果呈现：每条结果显示来源资料标题、相关度得分、文本片段，命中词以红色加粗高亮。

4.3 检索决策说明

软件在结果上方显示一行决策说明：



候选 M 条 · 资源约束：<理由>

这行说明的含义：告诉用户本次为什么只返回这几条——是内容层面判断"只有这几条相关"，还是资源层面"再多取就超出时间/内存预算"。

4.4 资料管理

功能	说明
资料列表	显示全部资料标题、来源类型、字符数
删除	删除资料并同步更新索引
统计	显示资料份数、片段数、待整理片段数
持久化	全部资料可序列化为 JSON 保存，启动时恢复

4.5 自测功能

软件内置一个自测页面，运行 14 项断言检查核心功能是否正常，结果以列表形式显示（通过/未通过）。

用途：在设备上验证软件核心逻辑的正确性，便于排查环境问题。

五、技术特点

5.1 不依赖词典的中文切词

手机端没有可用的中文分词词典，也无需为此引入数十兆的词表。本软件采用单字 + 相邻二元组的方式切词：

```
"离线资料库" → 离 / 线 / 资 / 料 / 库
              离线 / 线资 / 资料 / 料库
```

效果：不做分词也能达到可用的召回率，代价是索引词项数约为文本字数的两倍。 英文与数字按非字母数字切分并统一转小写。

5.2 由得分分布决定返回条数

这是本软件与同类工具最主要的区别。

多数检索工具返回固定条数（如前 3 条、前 10 条）。固定条数的问题在于：查询明确时返回过多无关内容，查询模糊时返回不足。

本软件的做法是观察候选的得分分布：

- 计算相邻候选得分的相对落差

- 找到最大落差所在位置
- 若该落差超过 5%，说明此处存在明显断层 —— 断层之前的是真正相关的
- 若分布平坦（无可信断层），说明无法区分相关程度，取上界
- 结果数量约束在用户设定的上下界之间

实测效果（150 条已知答案查询，真实语料 2,295 个片段）：

策略	召回率	精确率	平均返回条数
固定 3 条	100%	59.8%	3.0
本软件的得分分布策略	100%	89.4%	1.8

即：同样的召回率，精确率高约 30 个百分点，平均少返回 40% 的内容。

5.3 资源预算独立决策

软件区分两类问题：

问题	由什么决定
该取几条（信息层面）	候选的得分分布
还取得起几条（资源层面）	可用时间、可用内存、当前电量

两者取较小值，并在界面上显示是哪个在限制。电量低于 15% 时主动降级，减少返回条数以降低耗电。

设计意图：把"内容相关性"和"资源可用性"分开判断，而不是用一个"剩余额度"混为一谈。

5.4 分块随内容长度自适应

文本长度	分块大小	重叠
≤ 1,000 字	整篇一块	无
1,000 – 20,000 字	240 字	40 字
> 20,000 字	400 字	60 字

相邻块保留重叠，避免关键词被切在边界上导致漏检。

5.5 能力缺失时的降级设计

光学字符识别被设计为可替换接口而非硬依赖。

- 启动时先检查设备是否具备该能力
- 不具备时，拍照导入入口给出"请改用粘贴文本"的明确提示

- 其余功能（文本导入、检索、管理）完全不受影响

设计原因：在鸿蒙平台上，若应用静态引用设备不具备的 AI 能力模块，会导致应用在启动阶段直接终止，而不是功能不可用。因此核心算法模块与设备能力解耦，是保证应用可启动的必要条件。

5.6 增量删除与索引压缩

删除资料时采用标记删除而非立即重建索引：

- 删除只与该资料的片段数成正比
- 被删除片段在检索时跳过
- 标记比例超过 20% 时自动执行物理压缩

实测对比（1,000 份资料库删除 10 份）：

方式	耗时
立即重建索引	7,322 毫秒
标记删除	7.6 毫秒

5.7 存储容错

资料以 JSON 格式持久化。读取时逐条校验，遇到损坏条目跳过并继续，而非整体失败。

设计意图：一份存档中某一条损坏，不应导致用户失去其余全部资料。读取结果返回被跳过的条数。

六、数据结构

6.1 主要数据结构

结构	含义
DocItem	一份资料：标识、标题、来源类型、位置、入库时间、全文
Chunk	一个可检索片段：标识、所属资料、序号、原文起止位置、文本
Hit	一条检索命中：片段、相关度得分、命中的词项、高亮区间
ScoreDiagnostics	候选得分统计：候选数、最高分、均值、标准差、最大落差及位置
BudgetInput	资源预算输入：可用时间、可用内存、电量

SearchResult	检索结果：命中列表、实际条数、条数来源、诊断信息

6.2 持久化格式

```
{
  "version": 1,
  "docs": [
    {
      "id": "d1",
      "title": "示例资料",
      "source": "note",
      "uri": "note://...",
      "addedAt": 0,
      "text": "正文内容……"
    }
  ]
}
```

说明：只持久化资料本身，不持久化倒排索引。启动时从资料重建索引——个人资料量级下重建为秒级，且避免了索引格式变更导致旧存档失效。

七、错误处理

情况	处理方式
输入为空	提示"内容不能为空"，不入库
设备不支持 OCR	提示改用粘贴文本，其余功能正常
OCR 识别置信度过低	拒绝入库并提示原因
OCR 识别置信度中等	允许入库，但提示建议重拍
存档中部分条目损坏	跳过损坏条目，保留其余，返回跳过数量
检索无结果	显示"没有找到相关内容"，不报错
资料库为空时检索	提示先添加资料

八、版本说明

V1.0（本次登记版本）

已实现：

- 中英文切词（不依赖词典）

- 倒排索引与 BM25 相关度排序
- 高亮定位
- 由得分分布自适应决定返回条数
- 资源预算独立决策与低电量降级
- 内容长度自适应分块
- 资料导入（文本）、列表、删除、统计
- JSON 持久化与容错读取
- 增量删除与索引自动压缩
- OCR 抽象层与识别质量判定
- 设备内自测（14 项断言）
- 三页界面：搜索 / 资料 / 高级

规划中（不属于本次登记范围）：

- 真实 OCR 能力接入
- 文件与相册导入
- 检索结果按资料聚合去重
- 短语查询与布尔查询

九、开发与测试情况

9.1 开发方式

三人合作开发，分工如下：

成员	负责
（待填）	核心算法（切词、索引、检索、预算决策）
（待填）	界面与交互
（待填）	测试、实验与材料整理

9.2 测试情况

测试类型	数量	结果
单元测试	87 项	全部通过
设备内自测	14 项	全部通过
真实语料检索评估	150 条查询	召回率 100%，精确率 89.4%
编译验证	ArkTS 编译	通过

十、附注

- 本软件不申请网络相关权限，不发起任何网络请求，不向任何服务器传输数据。
- 本软件不包含生成式人工智能功能，不生成文本内容，仅检索并呈现用户自己的资料原文。
- 软件的全部数据处理均在本机完成。